

EMNIST 오토인코더 이상탐지 최적화

Hyperparameter Optimization and Anomaly Detection

Performance Evaluation of Autoencoder based on EMNIST Balanced Dataset

 6-Layer Structure

 RAdam Optimizer


 Swish Activation

 Test Acc 81.94%

PRESENTED BY

Team 3

오토인코더 구조 및 이상탐지 원리



구조: 압축과 복원

784 → ... → 32 → ... → 784 6-Layer Bottleneck 구조로 입력 데이터를 32차원 Latent Vector로 압축 후 복원

이상탐지 메커니즘

정상 데이터만 학습, 비정상 입력 시 높은 재구성 오차 발생으로 임계값 기반 이상 판정

깊은 구조의 이점

6-Layer 깊은 구조로 복잡한 비선형 관계 모델링 및 정교한 특징 추출, 낮은 재구성 오차 달성

사용 데이터셋과 선정한 성능 지표

EMNIST BALANCED DATA SET

손글씨 문자 데이터를 28x28 픽셀로 변환 데이터셋

47개 클래스(숫자 10개 + 대문자 26개 + 소문자 11개)의 샘플 수가 모두 동일

- 비슷한 모양의 대문자와 소문자는 하나의 클래스로 병합
- 클래스간 비율이 균등
- 131,600장의 이미지



성능 지표

ACCURACY

$$Accuracy = \frac{\text{올바르게 예측한 샘플 수 } (TP + TN)}{\text{전체 데이터 샘플 수 } (TP + TN + FP + FN)}$$

이상 탐지 결과에 대한 분류 정확도

균형잡힌 데이터셋으로 편향 없는 예측 달성

모델 구분력의 가장 직관적 시각화

하이퍼파라미터 구성 개요

오토인코더 성능 최적화를 위한 6가지 핵심 파라미터 및 설정 전략

Batch Size

탐색 범위: 32, 64, 128, 256

목표: 일반화 성능(Flat Minima)과 학습 안정성 간 균형 탐색

Learning Rate

탐색 범위: 0.01 ~ 0.0001

목표: Sharp Minima 문제 회피 및 최적 수렴 속도 확보

Layer & Node

구조: 3 ~ 7 Layers (Bottleneck 32)

목표: 데이터 표현력(Expressiveness)과 과적합(Overfitting) 사이 최적점

Optimizer

비교 대상: RAdam vs Adam vs NAdam

목표: 초기 학습 안정성(분산 보정) 및 최종 수렴 성능 평가

Loss & Activation

조합: MSELoss + Swish (SiLU)

목표: Sharp Landscape 평탄화(Smoothing) 및 Gradient Flow 개선

Anomaly Threshold

설정: Reconstruction Error 분포 기반

기준: 정상 데이터 오차의 95~99% 백분위수를 임계값으로 설정

KEY VARIABLES

✓ Optimizer

✓ Activation

*본 연구의 핵심 최적화 요소

Loss Function 설정

가설 수립

- 1 오토인코더의 구조적 특징을 활용
- 2 이상탐지의 본질은 정상과 비정상의 명확한 구분
- 3 데이터의 오차를 증폭시키면 이상 탐지에 효과적
- 4 오차를 제공하는 MSE Loss 사용

MSE LOSS

평균 제곱 오차

예측값과 실제값의 차이인 오차를 제곱한 뒤,
모든 데이터에 대해 평균을 구한 것

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

오차가 커질수록 손실값이 급격하게 증가

크게 틀릴 수록 더 큰 페널티 부여

빠르게 수정하도록 유도

- 구조적으로 크게 다른 이상 패턴에 대해 페널티를 증폭, 정상/이상 분포를 명확히 분리 가능

연구 배경 및 목적

 문제 제기: MSELoss의 딜레마

Sharp Landscape 형성

이상탐지에서 MSELoss는 이상치에 민감하게 반응하여 매우 뾰족하고 불규칙한 손실 지형(Loss Landscape)을 형성

- × 학습 불안정성: 최적화 과정에서 발산 위험
- × Local Minima: 뾰족한 최저점(Sharp Minima)에 갇힘 위험

Loss Function	Test Accuracy	Train Loss
MSELoss	0.8194	0.0139
L1Loss	0.7996	0.0460
HuberLoss	0.8093	0.0071

이론적 단점은 있지만 실험적으로 준수한 성능을 보임을 확인



 연구 가설 및 목표: 최적화 시너지

파라미터 별 경향성 파악


Optimizer, Activation Function 조합을 통한 단점 보완

목표 : 높은 이상 탐지력 유지

◎ 최종 목표 : 학습 불안정성을 다른 파라미터 최적화로 보완

모델 깊이 분석: 표현력 vs 과적합

Layer 수 변화에 따른 Test Accuracy 비교 및 최적 구조 탐색



LAYER	구조 (ENCODER STRUCTURE)	TEST ACC	STATUS
5	Shallow Structure 784-512-256-128-64-32	80.04%	Underfitting
6	Optimal Balance 784-600-512-256-128-64-32	81.94%	Best
7	Too Deep Structure 784-600-512-400-256-128-64-32	79.65%	Overfitting


FINAL CONCLUSION

"6-Layer 구조가 과소적합과 과적합 사이의 최적 균형점"

최고 성능 81.94% 달성

Learning Rate × Epoch 최적화

Epoch별 Test Accuracy 수렴 경향성



수렴 패턴 분석

Learning Rate 크기가 초기 수렴 속도 및 최종 일반화 성능에 결정적 영향

✓ 최적 균형점 (Optimal)


LR 0.0018 x Epoch 50 조합으로 가장 안정적 수렴 및 일반화 성능 극대화 달성

⚠ 과적합 및 발산 위험

LR 0.01의 높은 학습률은 초기 발산, 학습 진행 불가


Batch Size 분석

Batch Size별 Test Precision



i Batch 128 이상에서는 일반화 성능 저하 관찰

Minima Geometry 비교



✓ 최적 균형점: Batch Size 64


작은 배치의 느린 속도와 큰 배치의 Sharp Minima 문제 사이 최적점, 정규화 효과 및 학습 안정성 최적 균형 달성 (Test Precision : 82.87%)

왜 RAdam인가?

🏠 Optimizer 성능 비교 (Epoch 50)

Optimizer	Test Acc	Train Loss	Convergence
Adam	81.42%	0.0145	Unstable
RAdam	81.94%	0.0139	Stable
NAdam	81.67%	0.0141	Moderate

초기 학습 안정성 비교 (Early Phase)



분산 보정 (Variance Rectification)

초기 학습률 분산 자동 보정으로 Warm-up 없이도 초기 발산 효과적 방지




Sharp Landscape 극복

MSELoss의 Sharp 손실 지형에서도 흔들림 없는 안정적 Local Minima 탐색 및 강건성 제공

Swish 활성화 함수와 MSELoss의 시너지

Swish Function Geometry



$f(x) = x \cdot \text{sigmoid}(x)$

Key Advantages

Smoothing Effect (평탄화)

전 구간 연속 미분 가능으로 MSELoss Sharp 지형 평탄화 및 Flat Minima 수렴 유도

Non-Monotonicity (비단조성)

음수 영역 작은 값 허용으로 Dying ReLU 방지 및 풍부한 표현력 학습


MSELoss와의 궁합

MSE 이상치 민감성(탐지력) 유지하며 Swish로 학습 불안정성 완화, 민감하지만 안정적인 모델 구현

Loss Function Comparison

Loss Function	Test Acc	특징
MSELoss Best	81.94%	이상치 민감 (높은 구분력)
Huber Loss	80.93%	MSE와 L1의 절충안
L1 Loss	79.96%	이상치에 둔감 (탐지력↓)

Swish vs ReLU Training Loss



RAdam × Swish 시너지 메커니즘



최적화 시너지 (Optimization Synergy)



Swish의 Loss Landscape 평탄화(Smoothing) 후 RAdam의 초기 학습률 정교 제어(Stabilizing)로 Adam+ReLU 조합의 Local Minima 및 발산 문제 동시 해결

최종 성능 요약

TEST ACCURACY

81.94 %

✓ Highest Generalization Performance

VALIDATION ACC

87.25%

F1-SCORE (Test)

0.8168

PRECISION (Test)

82.87%

RECALL (Test)

80.53%

Final Optimal Configuration

Structure: 6-Layer


Optimizer: RAdam

Activation: Swish

Batch: 64

LR: 0.0018

1차 vs 2차 실험 경향성 비교



구분 (Settings)	1차 실험 (Baseline)	2차 실험 (Proposed)
Model Depth	3 Layers (Shallow)	6 Layers (Deep)
Latent Dim	8	32
Max Epochs	1024 Excessive	50 Optimal
Optimizer	Adam	RAdam + Swish
Validation Acc	93.3%	87.25%

⚠ 1차 실험의 한계 (과적합)

- 과도한 Epoch 1024 및 얇은 구조로 Validation 93.3% 달성했으나 학습 데이터 과적합, Test 검증 부재로 실제 성능 미담보

✅ 2차 실험의 성과 (일반화)

- Validation-Test Gap 약 5.3%로 축소(87.25% vs 81.94%)
- 과적합 해소 및 미지 데이터 안정적 대응 일반화 성능 확보

🔍 성능 개선 핵심 요인

- Radam 초기 안정성 x Swish 지형 평탄화 x Batch 64 정규화 결합으로 노이즈 배제 및 핵심 특징(Latent 32) 효과적 학습

결론 및 후속 연구

Final Conclusion: Sharp Landscape 극복

- Radam 분산 보정 x Swish 곡면 평탄화 x Batch 64 정규화 최적 조합으로 MSELoss 기반 학습 불안정성 해결
- Test Acc 81.94% 일반화 성공 및 산업 적용 가능 강건 모델 구축

Future Research Roadmap

Early Stopping

- Validation Loss 및 Sharpness 실시간 모니터링으로 최적 Epoch 자동 종료
- 과적합 원천 차단

Parameter Interaction Analysis

- Epoch 조정 시 잠재적 성능 개선 가능성 확인
- 파라미터 상호작용 심층 분석으로 최적화 경계 확장

Hardware Optimization

- Edge Device(NPU/FPGA) 경량화
- SW-HW Co-design으로 정확도 · 추론 속도 · 전력 효율 통합 최적화

Q&A